

Planejamento de Estudo Exploratório: Habitualidade Geográfica e Detecção de Anomalias em Transações de Cartão de Crédito

Arthur Garcia Takahashi¹

¹Programa de Pós-Graduação em Sistemas de Informação (PPGSI)
Escola de Artes, Ciências e Humanidades – Universidade de São Paulo (EACH-USP)
São Paulo – SP – Brasil

arthurgt@alumni.usp.br

Resumo. *Este trabalho apresenta o planejamento experimental para a detecção de fraudes, focando na análise de habitualidade geográfica. Inicialmente, testou-se a hipótese de que a distância física isolada seria um preditor suficiente, o que se provou inconclusivo. Através de um refino metodológico integrando categoria de consumo e janelas temporais, identificou-se anomalias significativas em categorias específicas, fundamentando a estratégia para o modelo de Aprendizado de Máquina subsequente.*

1. Introdução (Passo 1)

A detecção de fraude bancária exige a identificação de quebras de padrão comportamental. Este estudo busca responder: em que medida a divergência geográfica, segmentada por categoria de consumo e horário, atua como um preditor de anomalia robusto? O objetivo é validar se o "raio de consumo" pode reduzir falsos positivos em modelos supervisionados.

2. Materiais e Métodos (Passo 2)

Utilizou-se o simulador Sparkov [1], que mimetiza padrões de consumo reais. Para esta exploração inicial, extraiu-se uma amostra aleatória de 10% (55.572 registros de teste) via biblioteca *Pandas* [3]. O código fonte e os dados gerados estão documentados no GitHub [5]: <https://github.com/arthurgarciatakahashi/norton>.

3. Exploração Inicial: A Hipótese da Distância Isolada (Passo 3)

A primeira fase da exploração buscou validar a premissa de que transações fraudulentas apresentam distâncias geográficas significativamente maiores que as legítimas. Contudo, os resultados obtidos refutaram a simplicidade desta hipótese.

Conforme apresentado na Figura 1, a sobreposição dos quartis no boxplot indica que a distância, isoladamente, é um preditor fraco. Estatisticamente, a diferença entre as médias (75,84 km para legítimas vs 78,31 km para fraudes) revelou-se insuficiente para a separação linear das classes.




Figure 1. Comparativo de Distância Geográfica: A similaridade entre as classes indica a falha da hipótese univariada.

4. Refino e Análise Multivariada (Passo 7)

Diante da insuficiência da distância isolada, o estudo foi expandido para uma análise multivariada, cruzando a localização com a categoria de consumo e o horário da transação.

Esta abordagem revelou padrões ocultos de quebra de habitualidade. A Tabela 1 demonstra que, durante a madrugada (00h-06h), a categoria **food_dining** apresenta uma distância média de fraude de 122,74 km, um desvio de 46,89 km acima do padrão legítimo. O mapa de calor (Figura 2) confirma que a anomalia geográfica é contextual.

Table 1. Anomalias Geográficas por Categoria na Madrugada (00h-06h)

Categoria	Dist. Legítima	Dist. Fraude	Desvio (km)
food_dining	75,84 km	122,74 km	+46,90 km
misc_net	74,92 km	86,97 km	+12,05 km
grocery_pos	75,65 km	85,35 km	+9,70 km




Figure 2. Heatmap Multivariado: Identificação de clusters de fraude através da interação entre horário e categoria.

5. Planejamento da Execução

Com base na descoberta da habitualidade contextual, a questão de pesquisa foi refinada para focar na interação de variáveis. Planeja-se utilizar modelos de árvores de decisão (**Random Forest** e **XGBoost**), capazes de capturar as regras complexas identificadas na Tabela 1.

Cronograma de Passos Futuros:

- **Semana 1:** Engenharia de *features* (Interação Distância x Hora x Categoria).
- **Semana 2:** Treinamento e validação cruzada dos modelos.
- **Semana 3:** Otimização de hiperparâmetros para dados desbalanceados.
- **Semana 4:** Avaliação final e redação dos resultados.

References

- [1] Kaggle. *Credit Card Fraud Dataset*. 2026.
- [2] Sinnott, R. W. *Virtues of the Haversine*. 1984.
- [3] McKinney, W. *Data Structures for Python*. 2010.
- [4] Waskom, M. L. *Seaborn Visualization*. 2021.
- [5] Takahashi, A. G. *Repositório GitHub: /norton*. 2026.