

Análise de Habitualidade Geográfica e Detecção de Anomalias em Transações de Cartão de Crédito

Arthur Garcia Takahashi¹

¹Programa de Pós-Graduação em Sistemas de Informação (PPGSI)
Escola de Artes, Ciências e Humanidades – Universidade de São Paulo (EACH-USP)
São Paulo – SP – Brasil

arthurgt@alumni.usp.br

Resumo. *Este trabalho apresenta o planejamento experimental para a detecção de fraudes em cartões de crédito, focando na análise de habitualidade geográfica. Utilizando uma amostra de 10% do dataset Sparkov [1], explorou-se a relação entre a distância física da transação e a ocorrência de anomalias via Python [3]. Os resultados preliminares indicam que a distância média é sutilmente superior em fraudes, mas requer integração com outras variáveis para maior precisão.*

Abstract. *This paper presents the experimental planning for credit card fraud detection, focusing on geographic habituality analysis. Using a 10% sample of the Sparkov dataset [1], the relationship between transaction distance and anomalies was explored using Python [3]. Preliminary results indicate that the average distance is slightly higher in frauds, but requires integration with other variables for higher accuracy.*

Palavras-chave: Detecção de Fraude, Habitualidade Geográfica, Machine Learning.

Keywords: Fraud Detection, Geographic Habituality, Machine Learning.

1. Formulação da Questão de Pesquisa (Passo 1)

Este trabalho busca responder: em que medida a divergência geográfica entre o domicílio do portador e o local do estabelecimento, segmentada por categorias de consumo (físico e virtual), atua como um preditor de quebra de habitualidade? O objetivo é validar se o "raio de consumo" é uma variável robusta para reduzir falsos positivos em modelos de detecção de fraudes.

2. População e Coleta de Dados (Passo 2)

Utilizou-se o dataset Sparkov [1], um simulador de transações de cartões de crédito que mimetiza padrões de consumo reais com metadados geográficos. Para este experimento, foi extraída uma amostra aleatória de 10% do conjunto total de dados utilizando a biblioteca *Pandas* [3], totalizando 55.572 registros e preservando a distribuição original das classes. Os scripts desenvolvidos, incluindo a automação da ingestão de dados e o cálculo da métrica de Haversine [2], foram versionados e estão disponíveis para fins de reprodutibilidade no GitHub [5]: <https://github.com/arthurgarciatakahashi/norton>.

3. Análise Exploratória e Visualização (Passo 3)

A análise exploratória focou na criação da variável 'distância_km' via fórmula de Haversine [2] para testar a hipótese de que fraudes ocorrem em distâncias maiores. Os resultados estatísticos (Tabela 1) revelam que a distância média para transações legítimas é de 75,84 km, enquanto para transações fraudulentas a média é levemente superior, atingindo 78,31 km.

Essa proximidade entre as métricas indica que a distância geográfica, embora relevante, não atua como um preditor isolado de alta precisão, conforme visualizado no boxplot gerado com a biblioteca *Seaborn* [4] (Figura 1).

Table 1. Estatísticas Descritivas da Distância (km)

Classe	Média	Mínimo	Máximo	Amostra (n)
Legítima (0)	75,84	0,20	147,23	55.356
Fraude (1)	78,31	7,10	139,99	216




Figure 1. Comparativo da Distância Geográfica em Transações Legítimas (0) e Fraudulentas (1) - Escala Logarítmica.

4. Refino da Questão de Pesquisa (Passo 7)

A análise exploratória revelou que a distância média das fraudes é apenas 3,25% superior à das transações legítimas. Este resultado desmistifica a ideia de que a fraude se correlaciona obrigatoriamente com grandes deslocamentos físicos isolados.

Desta forma, a questão de pesquisa é refinada para: “Como a quebra de habitualidade geográfica pode ser ponderada em conjunto com a **categoria de consumo** e o **período do dia** para elevar a precisão na detecção de anomalias?”. O ambiente de experimentação estruturado para responder a esta pergunta encontra-se documentado no repositório oficial do projeto [5].

References

- [1] Kaggle. *Credit Card Fraud Detection Dataset 2023*. Disponível em: <https://www.kaggle.com/datasets/kartik2112/fraud-detection>. Acesso em: 23 mar. 2026.

- [2] Sinnott, R. W. *Virtues of the Haversine*. Sky and Telescope, vol. 68, no. 2, p. 159, 1984.
- [3] McKinney, W. *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference, pp. 51-56, 2010.
- [4] Waskom, M. L. *Seaborn: statistical data visualization*. Journal of Open Source Software, 6(60), 3021, 2021.
- [5] Takahashi, A. G. *Repositório de Experimentação em ML - Disciplina SIN5032*. GitHub, 2026. Disponível em: <https://github.com/arthurgarciatakahashi/norton>.